گزارش روند پروژه تحلیل دادهSuperstore

ابزارها Python 3.13 · Pandas · Numpy· Matplotlib · Seaborn · Jupyter · VS Code · Git

۱ .چکیده پروژه

این پروژه یک تحلیل اکتشافی کامل(EDA) روی دیتاست Superstore است که شامل ۹,۹۹۴ سفارش از یک فروشگاه زنجیره ای آمریکایی بین سال‌های ۲۰۱۵ تا ۲۰۱۸ می‌شود .

هدف پروژه ، پاسخ به ۵ سوال تجاری کلیدی و ارائه پیشنهادهای اجرایی بر اساس تحلیل داده ها است.

نکته متمایز پروژه: این پروژه با ساختار ماژولارپیاده‌سازی شده است.

به‌جای نوشتن همه کدها در یک فایلJupyter ، کدها به ماژول‌های مستقل پایتون شکسته شده اند و نوتبوک فقط نقش هماهنگکننده را ایفا می‌کند.

۲ .اهداف پروژه

پروژه با اهداف زیر تعریف شد:

کشف الگوهای فروش زمانی — آیا فروش فصلیت دارد؟

شناسایی دسته‌بندی‌های پرسود — کدام محصولات بیشترین سود را می‌سازند؟

تحلیل مناطق جغرافیایی— کدام مناطق بهترین عملکرد را دارند؟

بررسی تأثیر تخفیف— تخفیف چطور روی سود اثر می‌گذارد؟

تحلیل بخش مشتریان — کدام بخش بیشترین ارزش را می‌سازد؟

اهداف تکمیلی:

-پیاده‌سازی ساختار ماژولار مطابق اصول مهندسی نرم‌افزار

-پیاده‌سازی ۶ تمرین تکمیلی

-انتشار پروژه درGitHub

۳ .مراحل انجام پروژه(Timeline)

مرحله ۱ — تعریف مسئله و آماده‌سازی

-مطالعه فایل راهنمای استاد

-نصب و راه اندازی محیط Jupyter و VS Code

-آماده‌سازی دیتاست`Sample-Superstore.xlsx`

-ساخت اکانتGitHub

مرحله ۲ — بارگذاری و بررسی اولیه داده

-بارگذاری دیتاست باPandas

-بررسی ساختار داده: ۹,۹۹۴ ردیف × ۲۱ ستون

-بررسی مقادیر گمشده) ۱۱ ردیف درPostal Code)

-بررسی آمار توصیفی

مرحله ۳ — پاک‌سازی داده

مراحل پاک‌سازی انجام‌شده:

مرحله	عمل	نتیجه
۳,۱	حذف تکراری‌ها بر اساس **Order ID**	حذف ۴,۹۸۵ ردیف
۳,۲	تبدیل ۴ ستون به**`category`**	`کاهش مصرف حافظه
۳,۳	فیلتر مقادیر نامعتبر	حذف ۳۰ ردیف
۳,۴	ساخت ستون‌های زمانی	Year, Month, Month_Year, Quarter, Shipping Days

نتیجه نهایی: ۴,۹۷۹ ردیف تمیز برای تحلیل.

مرحله ۴ — تحلیل اکتشافی(EDA)

پنج تحلیل اصلی انجام شد:

1. روند فروش ماهانه — با شناسایی فصلیت
2. فروش و سود به تفکیک دسته‌بندی— با محاسبه حاشیه سود
3. عملکرد مناطق— با تحلیل سه‌شاخصی (فروش، سود، حاشیه سود)
4. تأثیر تخفیف بر سود— با رسم رگرسیون
5. سهم بخش مشتریان — با محاسبه درصدی

مرحله ۵ — مصورسازی

۵. نمودار کلیدی مستقل

-یک داشبورد یکپارچه GridSpec شامل ۵ زیرنمودار

-ذخیره همه نمودارها در پوشه`images/`

مرحله ۶ — تمرین‌های تکمیلی

شش تمرین از فایل استاد انجام شد:

1. میانگین زمان ارسال — با هیستوگرام
2. شناسایی سفارش‌های زیان‌ده — به تفکیک دسته و منطقه
3. ۵ زیردسته برتر — با نمودار میله‌ای
4. سهم Segment از فروش — با نمودار پای
5. تحلیل فصلی — با (Quarter) نمودار میله‌ای
6. ماتریس همبستگی — با Heatmap

مرحله ۷ — بازسازی ماژولار (Refactoring)

بر اساس بازخورد استاد، پروژه از حالت تکفایل به ماژولار بازسازی شد:

-ساخت پوشه `src/` برای ماژول‌های پایتون

-جداسازی کدها به ۶ ماژول مسئولیت‌محور:

— `data_loader.py` - بارگذاری داده

— `data_cleaning.py` - پاک‌سازی

— `feature_engineering.py` - ساخت ویژگی

— `eda.py` - تحلیل‌ها

— `visualization.py` - مصورسازی

— `practice.py` - تمرین‌های تکمیلی

-بازنویسی نوتبوک‌ها به‌صورت **Orchestrator** (فقط صدا زدن ماژول‌ها)

مرحله ۸ — مستندسازی و تحویل

-نوشتن `README.md` حرفه‌ای

-ساخت `requirements.txt`

-ساخت `.gitignore`

-تبدیل نوتبوک‌ها به HTML

-Push به GitHub

۴ .چالش‌های پروژه و نحوه حل.

چالش ۱: ریزش شدید داده‌ها در فرآیند پاک‌سازی(Data Loss)

شرح چالش:در مرحله پاک‌سازی، استفاده از دستور drop_duplicates(subset=['Order ID'])منجر به حذف ۴,۹۸۵ ردیف (حدود ۵۰٪ داده‌ها) شد. این موضوع نشان‌دهنده یک ریسک جدی در تحلیل بود.

تحلیل و راه‌حل:بررسی ساختار داده نشان داد که هر Order IDمی‌تواند شامل چندین محصول (Product ID) متفاوت باشد. بنابراین، حذف تکراری‌ها صرفاً بر اساس Order IDیک تصمیم نادرست تحلیلی بود.

تصمیم نهایی:برای تحلیل‌های سطح سفارش(Order Level) ، ترکیب Order IDو Product IDبه عنوان کلید یکتا در نظر گرفته شد. همچنین شفاف‌سازی شد که برای تحلیل‌های سطح محصول، نباید از subsetاستفاده کرد تا اقلام یک فاکتور حفظ شوند. این چالش منجر به تعریف دقیق «واحد تحلیل» (Unit of Analysis)در پروژه شد.

چالش ۲ : هشدار FutureWarning در Seaborn

مشکل:با `sns.barplot` بدون`hue` ، هشدار `FutureWarning` ظاهر می‌شد.

راه‌حل: اضافه کردن `hue='...'` و `legend=False` به همه barplot ها.

چالش ۳ : خطای `jupyter nbconvert` در ترمینال

مشکل:دستور `jupyter nbconvert` در ویندوز شناخته نمی‌شد.

راه‌حل: استفاده از `jupyter nbconvert!` خطا برطرف شد.

چالش ۴ — GridSpec :هم‌پوشانی نمودارها

مشکل:در داشبورد ۵ نموداره، بعضی محورها هم‌پوشانی داشتند.

راه‌حل: استفاده از `plt.tight_layout()` و تنظیم دقیق `height_ratios` و `width_ratios`.و `tick_params(axis='x', labelrotation=45)`

چالش ۵: تفاوت با اصول ماژولار

مشکل: ساختار اولیه پروژه به صورت یکپارچه (Monolithic)در یک فایل Jupyter پیاده‌سازی شده بود بر اساس الزامات پروژه، بازسازی کامل به ساختار ماژولار انجام شد .

راه‌حل: بازسازی کامل پروژه به ساختار ماژولار با ۶ فایل پایتون و بازنویسی نوت‌بوک‌ها به‌صورت Orchestrator.

چالش ۶: مسیر فایل اکسل در ماژول‌ها

مشکل: مسیرهای نسبی مثل `../data/` در Jupyter درست کار نمی‌کردند.

راه‌حل: استفاده از مسیر مطلق با raw string: `r'C:\...\data\Sample-Superstore.xlsx'`.

۵. تصمیمات کلیدی پروژه

تصمیم	دلیل
استفاده از دیتاست واقعی به‌جای شبیه‌سازی	نمایش مهارت با داده واقعی
تحلیل در سطح سفارش (نه محصول)	چون Order ID تکرار می‌شود
تمرکز بر ۵ سوال تجاری کلیدی	مطابق فایل استاد
تحلیل سه‌شاخصی مناطق (فروش + سود + حاشیه)	پاسخ کامل به «بهترین عملکرد»
استفاده از GitHub برای نسخه‌بندی	استاندارد پروژه‌های حرفه‌ای
بازسازی ماژولار پروژه	بازخورد مستقیم استاد

۶. مهارت‌های به‌کار رفته

- Python: Pandas, NumPy, Matplotlib, Seaborn

Data Cleaning: حذف تکراری، Type Conversion، فیلتر مقادیر نامعتبر

Feature Engineering استخراج Year, Month, Quarter از تاریخ

Groupby Aggregation با چندین متریک همزمان

Visualization نمودار خطی، میله‌ای، دایره‌ای، هیستوگرام، Heatmap، Regplot

GridSpec چیدمان چندین نمودار در یک Figure

Modular Programming - جداسازی کد به ماژول‌های مسئولیت‌محور

Python Imports - ماژول‌های نسبی و مطلق

Markdown: مستندسازی حرفه‌ای

Git & GitHub نسخه‌بندی و انتشار

۷. یادگیری‌ها

1. داده‌ی تمیز» مهم‌تر از «کد زیبا» است بدون پاکسازی درست، نتایج گمراه‌کننده می‌شوند.

2. تفسیر نمودار مهم‌تر از خود نمودار است نمودار بدون تفسیر تحلیلی، فاقد ارزش تجاری و تصمیم‌ساز است
3. ساختار ماژولار، نگهداری کد را آسان می‌کندهر تابع در فایل مربوط به خودش.
4. مستندسازی حین کار بهتر از مستندسازی در پایان است.
5. GitHubبخش جدایی‌ناپذیر پروژه‌های تحلیل داده است.
6. تفاوت شاخص‌های عملکردی — فروش حجم را نشان می‌دهد، ولی حاشیه سود کارآمدی را.

۸.وضعیت نهایی تحویل

بخش	وضعیت
نوتبوک اصلی	کامل (`analysis_modular.ipynb`)
نوتبوک تمرین‌ها	کامل (`practice_modular.ipynb`)
۶ ماژول پایتون در `src/`	کامل
خروجی HTML هر دو نوتبوک	ساخته شد
README.md حرفه ای	نوشته شد
requirements.txt	ساخته شد
.gitignore	ساخته شد
GitHub Repository	Push شد

۹ .پیشنهاد برای پروژه‌های بعدی

-استفاده از دیتاستهای بزرگتر مثل(Kaggle)

-اضافه کردن Machine Learning برای پیش‌بینی فروش

-ساخت داشبورد تعاملی با Plotly یا Streamlit

-اضافه کردن Unit Testing برای ماژول‌ها (pytest)

-اضافه کردن(Continuous Integration (GitHub Actions